

Анализа сеоских реклама коришћењем метода правила придруживања, кластеровања и класификације

Богдан Мировић 1090/2025

3. октобар 2026.

Садржај:

1. Задатак	2
2. Опис података	2
3. Претпроцесирање података	2
3.1 Учитавање	2
3.2 Елиминација дупликата	2
3.3 Чишћење текста	3
3.4 Трансформација података	3
3.4.1 За правила придруживања	3
3.4.2 За кластеровање и класификацију	3
3.5 Визуализација	4
4. Правила придруживања	5
4.1 Општа правила	6
4.2 Правила прихваћених реклама	7
4.3 Правила одбијених реклама	8
5. Кластеровање	9
5.1 Метрике евалуације	9
5.2 К средина	9
5.2.1 Reduced stripped	10
5.2.2 Full stripped	12
5.3 Бисекција к средина	13
5.3.1 Reduced stripped	14
5.3.2 Full stripped	15
5.4 Агломеративно кластеровање	17
5.4.1 Reduced stripped	17
5.4.2 Full stripped	18
5.5 hdbscan	20
5.6 Гаусова мешавина модела	22
5.6.1 Reduced stripped	23
5.6.2 Full stripped	25

5.7	Закључак	27
6.	Класификација	28
6.1	Bagging	28
6.2	Random Forest	29
6.3	XGBoost	29
6.4	Support vector machine	30
6.5	Logistic regression	31
6.6	Поређење резултата	31
6.6.1	Поређење ROC-AUC по скупу података:	31
6.6.2	Поређење тачности по скупу података:	32
6.6.3	Поређење ROC-AUC моделу:	32
6.6.4	Поређење тачности по моделу:	32

1 Задатак

Циљ пројекта је анализа скупа података сеоских реклама коришћењем метода правила придуживања, кластеровања и класификације. Задатак обухвата следеће кораке:

- Извршити претпросесирање података.
- Податке обратиди коришћењем минимум 5 алгоритама.
- Извршити анализу решења: Упоредити резултате добијене различитим алгоритмима и протумачити их
- Визуелно приказати податке у 2D или 3D простору.
- Направити моделе са свим атрибутима и са редукованим скупом атрибута и поредити их.

2 Опис података

Ови подаци су скупљени из текстова реклама са 12 вебсајтова који се баве различитим темама у вези са сеоским животињама. Бинарна обележја су базирана на томе да ли је власник садржаја одобрио рекламу. Подаци обухватају садржај саме рекламе као и вебстранице ка којима рекламе воде. Свакој речи са самих реклама је додат префикс ad-, Title- и header- HTML тагови су на сличан начин обележени за текст са сајта ка којем реклама води. Већ је одрађено стемовање (stemming) и stop word removal. Свака реклама је у једном реду. Прва реч у реду је обележје дате инстанце. 1 је за прихваћене рекламе а -1 за одбијене рекламе. Скуп података такође садржи и репрезентацију коришћењем метода вреће речи (Bag of words) у SVMlight формату. Број инстанци је 4143 а број атрибута је 54877.

3 Претпроцесирање података

3.1 Учитавање

Прво се учитава farm-ads датотека и с обзиром да је у њој сваки ред једна ставка могу се лако раздвојити обележја и текст и да се од датих података направи pandas dataframe. Постоје 4143 ставке од којих су 3269 уникатни текстови а 34 се понављају.

3.2 Елиминација дупликата

Прво се врши провера да ли међу рекламама постоје текстови код којих дупликати имају различита обележја. Може се видети да постоји 4 таква текста који чине укупно 16 редова. Не постоји начин да се одреди која обележја су исправна тако да су све рекламе са сукобљеним обележјима уклоњене. Код осталих реклама са дупликатима су уклоњени само дупликати.

3.3 Чишћење текста

Текст садржи остатке URL-ова, HTML тагове као и неке неинформативне термине са вебсајтова који се често појављују и не доприносе анализи. Ручно је направљен скуп свих таквих термина који су избачени из текстова. Текстови се даље деле на 2 скупа:

- Префиковани текстови (prefixed texts) - текстови који садрже ad- header- и title- префиксе који указују на то одакле је дата реч узета.
- Огуљени текстови (stripped texts) - текстови са којих су скинути префикси.

3.4 Трансформација података

3.4.1 За правила придруживања

Да би подаци били у облику погодном за алгоритме правила придруживања потребно је извршити бинаризацију. Алгоритми раде над ставкама (присутним или одсутним) тако да од текста правимо вектор нула и јединица користећи count_vectorizer функцију sklearn библиотеке. За параметре је постављен binary=True зато што није битно колико пута се дата реч појављује у тексту него само да ли се појављује или не. min_df = 0.01 одбацује речи које су присутне у мање од 1% текстова зато што су превише ретке да би биле информативне. На сличан начин је постављено max_df = 0.95 да би биле занемарене речи које се појављују у преко 95% текстова и превише су честе да би биле информативне. Параметар token_pattern=r'[a-zA-Z][a-zA-Z]+' је потребан зато што count_vectorizer подразумевано дели речи у којима се појављује цртица(-) на две речи. Постављени су и засебни атрибути за прихваћену рекламу и одбијену рекламу. Након обраде добијамо скупове података облика:

```
Stripped_df matrix shape: (3265, 3533)
Prefixed_df matrix shape: (3265, 3783)
```

3.4.2 За кластеровање и класификацију

За кластеровање и класификацију текстови су трансформисани коришћењем tfidf_vectorizer функције библиотеке sklearn. Параметри су исти као код count_vectorizer функције уз додатак параметра sublinear_tf=True којим се подаци скалирају да би се смањио утицај превише честих речи.

Даље је извршена редукција атрибута коришћењем TruncatedSVD функције. Број компоненти је одређен тако да удео објашњене варијансе буде преко 80%.

На крају су подаци нормализовани и тиме је добијен векторски простор у којем је еуклидска дистанца сразмерна косинусној.

Крајњи резултати претпроцесирања су:

```
TF-IDF reduced stripped:
TF-IDF matrix shape: (3265, 3531)
LSA explained variance: 83.53%
Reduced matrix shape: (3265, 700)
```


TF-IDF reduced prefixed:
TF-IDF matrix shape: (3265, 3781)
LSA explained variance: 83.77%
Reduced matrix shape: (3265, 700)

TF-IDF full stripped:
TF-IDF matrix shape: (3265, 43563)
LSA explained variance: 82.00%
full matrix shape: (3265, 1100)

TF-IDF full prefixed:
TF-IDF matrix shape: (3265, 54734)
LSA explained variance: 82.21%
full matrix shape: (3265, 1200)

3.5 Визуализација

Анализом главних компоненти добијени су следећи графици:



На графицима се види јасна разлика између редукованих и пуних скупова података као и између редукованог огуљеног и редукованог префиксованог. Између пуног огуљеног и пуног префиксованог нема велике разлике на слици.

4 Правила придруживања

За анализу правила придруживања коришћен је скуп огуљених података зато што је циљ наћи које речи се појављују заједно и није битно у ком делу рекламе се дата реч појављује. Поделом речи на основу места појављивања се непотребно дели једна иста реч на више различитих атрибута. За одређивање скупа честих скупова речи коришћен је `fpgrowth` алгоритам зато што је ефикаснији од `apriori` алгоритма а даје исте резултате. `min_support = 10` одбацује скупове који се појављују у мање од 10% инстанци. Постављањем параметра на број већи од тога би се постигло добијање само још чешћих скупова али би се тиме потенцијално одбацили скупови који се ређе појављују али су значајни. `association_rules` функцијом и параметрима `metric = 'confidence'` и `min_threshold = 0.6` су добијена само правила код којих се глава правила појављује у преко 60% појављивања тела правила.

Генерисана су 3 скупа правила:

- Општа
- Правила чији је исход прихваћена реклама
- Правила чији је исход одбијена реклама

Правила су даље сортирана према вредности `lift` мере. `Lift` мера представља однос између стварне учесталости заједничког појављивања речи и учесталости која би се очекивала под претпоставком њихове независности. Вредности веће од 1 указују на позитивну повезаност.

4.1 Општа правила

	antecedents	consequents	support	confidence	lift
	code	zip	0.107000	0.682000	5.266000
	zip	code	0.107000	0.827000	5.266000
	dog	cat	0.102000	0.621000	5.080000
	cat	dog	0.102000	0.837000	5.080000
	symptom	cause, treatment	0.105000	0.635000	4.398000
	cause, treatment	symptom	0.105000	0.726000	4.398000
	cause, treatment	disease, label_rejected	0.104000	0.720000	4.384000
	disease, label_rejected	cause, treatment	0.104000	0.632000	4.384000
	disease, treatment	cause, label_rejected	0.104000	0.640000	4.253000
	cause, label_rejected	disease, treatment	0.104000	0.690000	4.253000
	disease, label_rejected, treatment	cause	0.104000	0.796000	3.997000
	dog	label_accepted, pet	0.115000	0.701000	3.965000
	label_accepted, pet	dog	0.115000	0.653000	3.965000
	symptom, treatment	cause	0.105000	0.760000	3.818000
	disease, treatment	symptom	0.101000	0.625000	3.783000
	symptom	disease, treatment	0.101000	0.614000	3.783000
	dog, label_accepted	pet	0.115000	0.769000	3.705000
	weight	loss	0.104000	0.611000	3.695000
	loss	weight	0.104000	0.631000	3.695000
	dog	pet	0.126000	0.764000	3.679000

Прва два правила су $\text{code} \Rightarrow \text{zip}$ и $\text{zip} \Rightarrow \text{code}$ и немају велики значај. Може се такође видети да се `cat` и `dog` појављују заједно. Термини који указују на неки тип болести се често појављују заједно а може се видети и да указују на одбијену рекламу.

4.2 Правила прихваћених реклама

antecedents	consequents	support	confidence	lift
dog	label_accepted, pet	0.115000	0.701000	3.965000
photo	label_accepted, video	0.110000	0.606000	3.058000
horse	label_accepted	0.126000	0.951000	1.717000
animal, video	label_accepted	0.106000	0.928000	1.675000
animal, pet	label_accepted	0.114000	0.923000	1.666000
dog, pet	label_accepted	0.115000	0.917000	1.656000
cat	label_accepted	0.112000	0.915000	1.651000
dog	label_accepted	0.150000	0.911000	1.644000
animal, care	label_accepted	0.105000	0.910000	1.642000
animal	label_accepted	0.179000	0.889000	1.604000
category, health	label_accepted	0.103000	0.870000	1.571000
favorite	label_accepted	0.106000	0.868000	1.566000
pet	label_accepted	0.177000	0.851000	1.536000
farm	label_accepted	0.145000	0.849000	1.533000
pet, video	label_accepted	0.104000	0.847000	1.529000
care, pet	label_accepted	0.115000	0.839000	1.515000
email, ship	label_accepted	0.101000	0.836000	1.509000
health, pet	label_accepted	0.101000	0.829000	1.496000
food, pet	label_accepted	0.109000	0.828000	1.495000
customer, video	label_accepted	0.105000	0.816000	1.473000

Код ових правила се јасно може видети да спомињање животиња у реклами указује на велику вероватноћу да ће реклама бити прихваћена. Мера поверења је изразито велика код свих правила, поготово код оних где је глава само label_accepted. Могу се видети и поједини неживотињски изрази попут photo, video, category, health, favorite, care, email, ship, customer.

4.3 Правила одбијених реклама

antecedents	consequents	support	confidence	lift
cause, treatment	disease, label_rejected	0.104000	0.720000	4.384000
disease, treatment	cause, label_rejected	0.104000	0.640000	4.253000
cause, disease	label_rejected, treatment	0.104000	0.760000	3.545000
symptom	label_rejected, treatment	0.118000	0.714000	3.332000
cause	label_rejected, treatment	0.125000	0.628000	2.928000
doctor	label_rejected, treatment	0.107000	0.625000	2.917000
doctor, treatment	label_rejected	0.107000	0.895000	2.007000
patient	label_rejected	0.121000	0.882000	1.978000
cause, disease, treatment	label_rejected	0.104000	0.878000	1.969000
cause, treatment	label_rejected	0.125000	0.866000	1.943000
symptom, treatment	label_rejected	0.118000	0.856000	1.919000
cause, disease	label_rejected	0.115000	0.839000	1.880000
symptom	label_rejected	0.136000	0.826000	1.851000
disease, treatment	label_rejected	0.130000	0.804000	1.802000
treatment	label_rejected	0.214000	0.794000	1.780000
condition, treatment	label_rejected	0.104000	0.789000	1.770000
doctor	label_rejected	0.134000	0.781000	1.752000
cause	label_rejected	0.150000	0.755000	1.694000
health, treatment	label_rejected	0.107000	0.706000	1.583000
disease	label_rejected	0.164000	0.693000	1.555000

Овде је слика такође јасна, болест и медицински термини указују на велику вероватноћу да је реклама одбијена, на читавом списку тела правила не постоји ниједан израз који нема везе са болешћу.

5 Кластеровање

5.1 Метрике евалуације

За евалуацију квалитета кластера коришћене су 3 стандардне метрике:

- Силуэта коефицијент (Silhouette score) - мери колико је свака тачка слична сопственом кластеру у поређењу са најближим суседним кластером. Вредности су у опсегу $[-1, 1]$. Вредности ближе 1 указују на добро дефинисане кластере.
- Давиес-Боулдинов индекс (Davies-Bouldin index) - мери просечну сличност сваког кластера са њему најсличнијим кластером. Ниже вредности су боље.
- Цалински-Харбасзов индекс (eng. Calinski-Harbasz index) - однос између међукластерске и унутаркластерске распршености. Више вредности су боље.


5.2 К средина

Алгоритам к средина је примењен на сва 4 скупа података:

- Reduced stripped
- Reduced prefixed
- Full stripped
- Full prefixed


На основу графика инерције и све 3 мере квалитета не постоји број кластера који се истиче као природна подела ниједног скупа података. Све мере квалитета релативно униформно настављају да се побољшавају тако да је потребно изабрати број кластера који даје довољно добре резултате а да је истовремено довољно мали да је могуће анализирати кластере. У овом случају је изабран број 38 и користи се за сва 4 скупа.

Графици показују да су резултати значајно лошији над Reduced prefixed скупом података, Full prefixed је сличан Full stripped скупу а Reduced stripped показује најбоље резултате. Пример:



Тако да су направљени крајњи модели само за Reduced stripped и Full stripped. Остали алгоритми су такође примењени само на та 2 скупа.

5.2.1 Reduced stripped



На графикону изнад се може видети да постоји 1 кластер који се истиче по величини са чак преко 700 инстанци, након њега постоје још 3 кластера који имају између 250 и 300 а након тога су сви мањи.

true_label	accepted	rejected	total	pct_accepted	top_terms
cluster					
1	68	0	68	100.000000	law, veterinary, justanswer, avatar, jpg, veterinarian, upload, appliance, positive, accept
30	15	0	15	100.000000	kitten, cat, identification, neuter, rescue, club, tag, behavior, adoption, checklist
25	43	0	43	100.000000	platinum, athletic, performance, pak, reproduction, hoof, equine, density, allergy, metabolic
19	36	0	36	100.000000	pet, supply, trust, rabbit, drsfostersmith, foster, guinea, cage, smith, name
15	18	0	18	100.000000	goat, dairy, fence, raise, acreage, subscription, beautiful, magazine, country, pond
8	31	0	31	100.000000	poultry, geese, chicken, coop, backyard, acreage, raise, duck, country, bantam
26	20	0	20	100.000000	hobby, livestock, poultry, farm, alpaca, post, coop, thread, hydraulic, backyard
27	20	0	20	100.000000	hunt, deer, goose, predator, creek, call, game, fox, electronic, sound
23	25	1	26	96.200000	classifi, agriculture, ag, livestock, machinery, hog, deere, classify, buyer, crop
28	23	1	24	95.800000	smoothie, loser, smoothy, biggest, nbc, fruit, tuesday, frozen, idea, cool
37	23	1	24	95.800000	insurance, security, coverage, limit, license, pet, internet, quote, rate, company
11	35	2	37	94.600000	acai, berry, colon, julia, trial, cleanse, diet, lost, week, lose
35	63	4	67	94.000000	hunt, ranch, deer, trophy, texa, lodge, cattle, hunter, bull, mountain
17	56	4	60	93.300000	soap, oil, natural, handmade, bath, milk, goat, skin, lotion, scent
21	63	7	70	90.000000	alert, oop, visibility, exist, newly, upper, unable, list, invalid, private
4	52	11	63	82.500000	nj, brunswick, piscataway, restaurant, mi, review, feed, phone, local, map
13	36	8	44	81.800000	compare, yahoo, rabbit, amazon, deal, price, sponsor, coupon, result, shop
29	125	29	154	81.200000	cheese, recipe, milk, meat, flash, food, installation, cook, flavor, delicious
12	239	65	304	78.600000	pet, dog, shop, price, ship, gift, accessory, sale, food, cart
9	22	7	29	75.900000	livestock, business, equipment, supply, quickly, found, cattle, solution, meat, handle
16	171	90	261	65.500000	diet, weight, health, loss, healthy, body, food, lose, supplement, fat
24	440	278	718	61.300000	email, please, time, business, call, sale, available, family, farm, day
0	21	20	41	51.200000	acr, farm, land, estate, county, house, sale, equipment, city, tractor
10	10	12	22	45.500000	pygmy, goat, compare, yahoo, hire, deal, amazon, coupon, result, contractor
5	63	89	152	41.400000	found, symptom, cough, disease, treat, pig, candy, animal, answer, prevent
32	57	91	148	38.500000	equipment, system, steel, tank, application, design, fence, water, engineer, industry
14	8	35	43	18.600000	rheumatoid, arthritis, everyday, pain, health, symptom, ra, rheumatic, rheumatologist, relaxation
2	26	257	283	9.200000	treatment, symptom, disease, patient, cause, pain, health, therapy, fibromyalgia, medical
3	0	121	121	0.000000	ivf, donor, fertility, sperm, egg, attain, bank, cycle, reproductive, baby
7	0	56	56	0.000000	aqualyse, legionella, ionisation, ion, facility, ionization, proposal, water, copper, domestic
20	0	27	27	0.000000	cancer, treatment, found, innovative, diagnosis, edge, lead, chat, option, oncology
18	0	35	35	0.000000	volkswagen, gti, rabbit, cylinder, hatchback, stabilization, esp, clearance, standard, door
6	0	15	15	0.000000	dentist, gum, dental, teeth, tooth, teen, coverage, cavity, oral, plaque
22	0	21	21	0.000000	mesothelioma, lung, cancer, lawyer, attorney, lawsuit, chest, line, respiratory, symptom
33	0	63	63	0.000000	crohn, disease, symptom, colitis, bowel, ulcerative, cause, treatment, drug, healthline
31	0	51	51	0.000000	disc, spine, spinal, facet, stenosis, degenerative, seminar, mri, pain, surgery
34	0	40	40	0.000000	pregnancy, pregnant, baby, week, toddler, calendar, development, labor, contest, ovulation
36	0	15	15	0.000000	cancer, md, colon, ovarian, detox, blog, kidney, lung, depression, pain

Кластер 23 је највећи са 718 инстанци и има 61.3% прихваћених реклама. Најчешће речи су: email, please, time, business, call, sale, available, family, farm, day. У питању су генерички бизнис и маркетинг термини тако да овај кластер вероватно обухвата све рекламе које се не истичу довољно по некој специфичној тематици и зато је највећи.

Следећи највећи кластер је кластер 12 са 304 инстанци и 78.6% прихваћених реклама. Најчешће речи су: pet, dog, shop, price, ship, gift, accessory, sale, food, cart. Термини указују на пет шоп и кластер има велики проценат прихваћених реклама. То се поклапа са информацијама добијеним из анализе правила придруживања где су дати термини асоцирани са прихваћеним рекламама.

Кластер 2 има 283 инстанци и 9.2% прихваћених реклама. Најчешће речи су: treatment, symptom, disease, patient, cause, pain, health, therapy, fibro-


myalgia, medical. Делује као кластер заједничких ветеринарских/медицинских термина. Сви кластери испод њега на листи су исто ветеринарски/медицински (осим кластера 18 који има аутомобилску тематику) и сви имају 0% прихваћених реклама. Ово се такође поклапа са закључцима из анализе правила придруживања.

Наредни највећи кластер је кластер 16 са 261 инстанци, 65.5% прихваћених реклама и најчешћим речима: diet, weight, health, loss, healthy, body, food, lose, supplement, fat. У питању су рекламе које се баве дијетом и мршављењем.

Већина преосталих кластера има јасну тематику и поклапа се са закључком да животиње и љубимци указују на прихваћену рекламу а болест и медицина на одбијену.

5.2.2 Full stripped

Код Reduced stripped скупа је још већа разлика у величини кластера. Највећи кластер има 986 инстанци, 60.3% прихваћених реклама и најчешће речи: design, email, sale, price, save, business, farm, time, equipment, call тако да је врло сличан највећем кластеру у reduced stripped скупу. Следећи највећи кластер одговара општем ветеринарском кластеру из претходног скупа али са већим бројем инстанци и већим процентом прихваћених реклама (438 и 31.7%). Код преосталих кластера се већином види јасна тематика и прате тренд да се медицински термини појављују у већој мери код одбијених реклама а животиње прихваћених. Занимљив изузетак је кластер од 68 прихваћених реклама који се појављује у оба скупа и има најчешће речи: law, veterinary, justanswer, avatar, jpg, veterinarian, upload, appliance, positive, accept.




true_label	accepted	rejected	total	pct_accepted	top_terms
cluster					
1	43	0	43	100.000000	platinum, athletic, performance, pak, reproduction, hoof, equine, density, allergy, metabolic
3	68	0	68	100.000000	law, veterinary, justanswer, avatar, jpg, veterinarian, upload, appliance, positive, accept
23	22	0	22	100.000000	yoplait, smoothie, loser, biggest, smoothy, nbc, tuesday, frozen, idea, cool
33	15	0	15	100.000000	trust, pet, supply, guinea, rabbit, drsfostersmith, found, name, pig, save
18	49	0	49	100.000000	acreage, raise, poultry, country, beautiful, subscription, chicken, magazine, pond, backyard
19	66	1	67	98.500000	hunt, deer, game, sound, cass, hunter, call, goose, creek, predator
17	60	1	61	98.400000	livestock, classify, farm, post, agriculture, ag, classify, breed, kitten, book
35	33	1	34	97.100000	cage, pet, supply, ferret, reptile, litter, bird, clearance, pond, dog
22	107	4	111	96.400000	dog, pet, cat, vet, veterinarian, food, asap, groomer, care, petplan
7	35	2	37	94.600000	acai, berry, colon, julia, trial, cleanse, diet, lost, week, lose
6	64	7	71	90.100000	alert, oop, visibility, exist, newly, upper, unable, list, invalid, private
4	228	26	254	89.800000	soap, recipe, oil, natural, milk, organic, goat, ingredient, food, fat
0	43	6	49	87.800000	alpaca, bull, sale, cattle, herd, llama, ranch, farm, heifer, fiber
13	38	6	44	86.400000	feed, mi, nj, piscataway, brunswick, local, mom, review, cattle, write
11	18	3	21	85.700000	parkchester, farm, equipment, staten, tractor, condominium, classifiedad, condo, word, location
10	16	5	21	76.200000	business, livestock, equipment, quickly, supply, found, cattle, mkt, commodity, solution
28	39	16	55	70.900000	compare, yahoo, amazon, deal, rabbit, coupon, price, sponsor, marketplace, result
21	23	10	33	69.700000	nj, mile, inaccurate, city, philadelphia, restaurant, nan, poultry, yellowpage, facebook
31	20	10	30	66.700000	queue, youtube, probiotic, view, probiotics, ago, load, video, nutrihealthprobiotic, playlist
25	595	391	986	60.300000	design, email, sale, price, save, business, farm, time, equipment, call
34	14	20	34	41.200000	lactaid, installation, flash, player, mcneil, website, disability, llc, social, nutritional
30	61	123	184	33.200000	found, cancer, treatment, enfamil, symptom, disease, whoop, baby, lollipop, cough
16	139	299	438	31.700000	treatment, health, disease, symptom, patient, medical, cause, doctor, diet, research
37	8	18	26	30.800000	ranch, land, county, realty, acr, auction, property, lake, sale, estate
15	2	35	37	5.400000	rheumatoid, arthritis, everyday, pain, ra, rheumatic, rheumatologist, symptom, health, relaxation
29	3	84	87	3.400000	symptom, disease, pain, cause, colitis, crohn, inflammation, arthritis, affect, treatment
5	0	56	56	0.000000	aqualyse, legionella, ionisation, ion, facility, ionization, proposal, water, copper, domestic
2	0	28	28	0.000000	pregnancy, contest, pregnant, trimester, baby, quiz, toddler, preconception, calendar, week
8	0	33	33	0.000000	volkswagen, gti, rabbit, cylinder, stabilization, hatchback, esp, standard, clearance, door
12	0	31	31	0.000000	disc, degenerative, spine, lsi, spinal, facet, mri, procedure, spondylosis, stenosis
20	0	8	8	0.000000	disposal, hw, waste, hazardous, trenton, biohazard, clinics, sharp, funeral, compliant
14	0	33	33	0.000000	ivf, attain, fertility, integram, baby, chance, cycle, refund, month, success
9	0	20	20	0.000000	mesothelioma, mesothelioma, asbesto, happyhealthyrecipe, lung, cancer, mesothelium, lawyer, lawsuit, attorney
24	0	15	15	0.000000	dentist, gum, dental, teeth, dentistry, periodontal, gums, tooth, teen, xxx
26	0	75	75	0.000000	donor, sperm, bank, egg, ivf, reproductive, donation, patient, fertility, embryo
27	0	43	43	0.000000	cancer, crohn, bipolar, depression, disease, healthline, lung, disorder, md, health
32	0	27	27	0.000000	ivillage, labor, chime, delivery, pregnancy, birth, baby, newsletter, whattoexpect, sex
36	0	19	19	0.000000	liu, spinal, asc, seminar, atlantic, stenosis, disc, facet, spine, endoscopic

5.3 Бисекција к средина

Бисекција к средина је модификација стандарног к средина алгоритма у којем се у сваком кораку један од кластера дели на 2. Тестирају се 2 стратегије, дељење највећег кластера и даљење које доводи до највећег пада инерције. Тестирањем над датим скуповима података се утврђује да стратегије дају врло сличне резултате тако да се у коначним моделима користи дељење највећег кластера.

5.3.1 Reduced stripped




Може се видети много мање концентрисана расподела инстанци по кластерима него код алгоритма к средина али због тога и мање кластера са 0% и 100% прихваћених реклама.

true_label	accepted	rejected	total	pct_accepted	top_terms
cluster					
0	68	0	68	100.000000	law, veterinary, justanswer, avatar.jpg, veterinarian, upload, appliance, positive, accept
10	18	0	18	100.000000	website, build, business, create, software, design, minute, customer, drag, custom
36	43	0	43	100.000000	platinum, athletic, performance, pak, reproduction, hoof, equine, density, allergy, metabolic
32	10	0	10	100.000000	remedy, flu, ailment, hair, throat, steam, chest, herbal, congestion, various
18	9	0	9	100.000000	false, truck, bx, tn, ok, june, oh, july, fl, august
4	106	1	107	99.100000	livestock, poultry, coop, chicken, backyard, farm, breed, raise, subscribe, subscription
15	71	1	72	98.600000	sale, puppy, alpaca, breeder, breed, bull, cattle, herd, farm, ranch
5	54	3	57	94.700000	soap, oil, handmade, bath, natural, milk, goat, skin, scent, lotion
7	51	3	54	94.400000	recipe, cheese, delicious, cook, dessert, cream, bak, flavor, bread, salad
11	14	1	15	93.300000	sound, effect, collection, ton, entertain, donate, fight, meal, llc, download
35	104	11	115	90.400000	weight, diet, lose, loss, pound, fat, acai, lb, week, healthy
2	64	7	71	90.100000	alert, oop, visibility, exist, newly, upper, unable, list, private, invalid
1	150	23	173	86.700000	rabbit, compare, pet, price, shop, yahoo, result, amazon, toy, cat
3	51	10	61	83.600000	nj, piscataway, brunswick, mi, restaurant, review, feed, local, phone, map
16	30	6	36	83.300000	insurance, security, limit, call, pet, coverage, company, save, rate, internet
6	139	47	186	74.700000	food, organic, natural, cart, milk, ship, price, shop, lb, goat
14	137	63	200	68.500000	email, day, price, sale, facebook, shop, re, time, market, view
13	105	50	155	67.700000	pet, dog, welcome, care, request, please, website, chicken, email, name
22	108	56	164	65.900000	hunt, deer, volkswagen, land, ranch, smoothie, acr, hunter, electronic, price
9	36	19	55	65.500000	image, youtube, video, bing, upload, jpg, similar, view, clip, sign
30	9	6	15	60.000000	disability, micro, block, url, disable, security, trend, risk, fibromyalgia, reputation
21	102	73	175	58.300000	found, livestock, supply, business, pig, equipment, rabbit, pet, quickly, trust
12	17	16	33	51.500000	restaurant, coupon, deal, discount, class, city, offer, spa, join, york
33	93	97	190	48.900000	health, disease, diet, body, vitamin, healthy, supplement, natural, cholesterol, symptom
20	78	91	169	46.200000	equipment, tank, design, fence, steel, system, horse, accessory, custom, application
19	71	92	163	43.600000	solution, technology, industry, management, system, business, company, control, application, customer
17	6	11	17	35.300000	installation, flash, player, nutritional, llc, website, audience, solely, content, encourage
8	8	17	25	32.000000	gift, baby, begin, diamond, family, registry, business, ring, account, card
28	40	154	194	20.600000	patient, treatment, disease, medical, research, doctor, therapy, symptom, physician, health
34	11	100	111	9.900000	symptom, disease, cause, pain, treatment, inflammation, affect, arthritis, crohn, colitis
27	4	55	59	6.800000	found, disease, symptom, parkinson, treatment, cough, crohn, answer, sclerosis, prevent
26	2	67	69	2.900000	rheumatoid, arthritis, symptom, health, drug, everyday, treatment, crohn, disorder, bipolar
24	0	173	173	0.000000	ivf, donor, fertility, baby, sperm, pregnant, pregnancy, egg, attain, infertility
25	0	60	60	0.000000	cancer, mesothelioma, treatment, lung, diagnosis, found, colon, md, lawyer, edge
29	0	20	20	0.000000	john, osteoporosis, alert, domain, guide, health, fracture, example, address, report
23	0	52	52	0.000000	disc, spine, spinal, facet, stenosis, degenerative, seminar, mri, pain, surgery
31	0	15	15	0.000000	dentist, gum, dental, teeth, tooth, teen, coverage, cavity, oral, plaque
37	0	56	56	0.000000	aqualyse, legionella, ionisation, ion, facility, ionization, proposal, water, copper, domestic

Најчешће речи су и даље врло сличне претходним резултатима уз мало мешања али су образци и даље јасни.

5.3.2 Full stripped

Врло слично као са Reduced stripped скупом, једина упечатљива разлика је мањи број кластера са 100% прихваћених реклама(само 1) и већи број са 0%.





true_label	accepted	rejected	total	pct_accepted	top_terms
cluster					
5	9	0	9	100.000000	nan, false, truck, tx, tn, wv, orlean, ok, june, nashville
23	78	2	80	97.500000	platinum, athletic, performance, weight, pak, reproduction, hoof, equine, support, density
21	25	1	26	96.200000	classifi, agriculture, ag, livestock, machinery, hog, deere, classify, buyer, crop
20	55	4	59	93.200000	soap, oil, natural, handmade, bath, milk, goat, skin, lotion, scent
2	64	6	70	91.400000	alert, oop, visibility, exist, newly, upper, unable, list, invalid, private
1	90	11	101	89.100000	nj, poultry, livestock, mi, city, feed, review, farm, brunswick, piscataway
3	159	23	182	87.400000	rabbit, pet, supply, compare, toy, shop, save, price, result, yahoo
8	52	8	60	86.700000	puppy, sale, bull, cattle, breeder, breed, akc, hereford, ranch, heifer
19	199	33	232	85.800000	food, recipe, organic, cheese, milk, natural, goat, meal, ingredient, dairy
22	117	29	146	80.100000	hunt, deer, equipment, yoplait, smoothie, hunter, acr, ranch, game, creek
9	9	3	12	75.000000	class, crunch, kickbox, fitness, schumann, guest, week, pass, tiger, bad
37	99	33	132	75.000000	law, justanswer, veterinary, rabbit, car, volkswagen, bird, expert, engine, veterinarian
7	102	37	139	73.400000	sale, alpaca, price, shop, farm, cart, ship, welcome, ranch, animal
16	47	17	64	73.400000	installation, lactaid, website, flash, player, homestead, mcneil, llc, image, web
35	140	60	200	70.000000	diet, weight, loss, health, healthy, lose, body, fat, food, cholesterol
12	90	49	139	64.700000	email, day, start, download, ll, name, video, sign, food, facebook
13	18	11	29	62.100000	queue, youtube, ago, view, shopathome, probiotic, nutrihealthprobiotic, upload, playlist, video
6	135	90	225	60.000000	pet, care, dog, natural, center, call, welcome, offer, design, experience
10	12	11	23	52.200000	steelmaster, whattoexpect, quote, email, deal, discount, offer, build, name,groupon
18	7	8	15	46.700000	enfamil, begin, gift, family, pringle, advice, register, grillin, baby, formula
4	36	43	79	45.600000	adt, donor, sperm, bank, security, insurance, tiffany, company, petplan, business
11	45	54	99	45.500000	name, time, market, email, trade, field, data, program, technology, company
14	103	127	230	44.800000	equipment, water, design, industry, solution, system, steel, fence, livestock, horse
17	80	105	185	43.200000	found, answer, whoop, lollipop, request, business, pig, bad, cough, sperm
15	3	19	22	13.600000	cryogenic, globalspec, fungus, nitrogen, liquid, lawn, storage, specification, tank, dewar
30	27	189	216	12.500000	symptom, disease, treatment, patient, cause, doctor, health, medical, disorder, care
36	8	84	92	8.700000	cancer, arthritis, health, rheumatoid, crohn, bipolar, symptom, depression, disorder, pain
0	56	56	112	0.000000	aqualyse, legionella, ionisation, ion, facility, ionization, proposal, water, copper, domestic
24	0	51	51	0.000000	disc, spine, spinal, facet, stenosis, seminar, degenerative, mri, pain, surgery
25	0	102	102	0.000000	ivf, fertility, attain, baby, pregnant, month, integram, pregnancy, treatment, success
29	0	26	26	0.000000	arthritis, joint, pain, rheumatoid, ra, osteoarthritis, knee, lupus, cause, affect
28	0	8	8	0.000000	palsy, cerebral, disability, fibromyalgia, social, disable, cp, assistive, spastic, security
27	0	9	9	0.000000	osteoporosis, bisphosphonate, fracture, copn, ontario, atypical, canada, oct, calcium, aware
26	0	38	38	0.000000	cancer, mesothelioma, mesothelloma, asbesto, lung, treatment, happyhealthyrecipe, mesothelium, diagnosis, found
33	0	11	11	0.000000	azilect, parkinson, intouch, prescrib, teva, neuroscience, de, disease, rasagiline, parkinsonshealth
32	0	47	47	0.000000	crohn, colitis, disease, ulcerative, symptom, bowel, colon, intestine, cause, inflammation
31	0	20	20	0.000000	hopkin, john, fibromyalgia, therapy, pain, youname, alert, domain, massage, myofascial
34	0	31	31	0.000000	dentist, treatment, gum, gums, dental, teeth, dentistry, williamsville, periodontal, dependence

5.4 Агломеративно кластеровање

5.4.1 Reduced stripped

На основу дендограма је одређено 12 кластера.






Добијена су 2 кластера која садрже велику већину инстанци. Већи кластер има најчешће речи: found, sale, pet, farm, business, price, call, email, supply, equipment. Није сасвим очигледна и концентрисана тематика.


У другом највећем кластеру су најчешће речи: health, disease, symptom, treatment, diet, healthy, body, weight, cause, food. Личи на претходно виђене медицинске кластере уз додатак исхране.

true_label	accepted	rejected	total	pct_accepted	top_terms
cluster					
6	49	0	49	100.000000	acreage, raise, poultry, country, beautiful, subscription, chicken, magazine, pond, backyard
9	68	0	68	100.000000	law, veterinary, justanswer, avatar, jpg, veterinarian, upload, appliance, positive, accept
7	43	0	43	100.000000	platinum, athletic, performance, pak, reproduction, hoof, equine, density, allergy, metabolic
3	35	2	37	94.600000	acai, berry, colon, julia, trial, cleanse, diet, lost, week, lose
5	62	6	68	91.200000	alert, oop, visibility, exist, newly, upper, unable, list, private, invalid
0	89	27	116	76.700000	yahoo, review, compare, result, deal, write, amazon, coupon, shop, price
1	1007	644	1651	61.000000	found, sale, pet, farm, business, price, call, email, supply, equipment
2	454	515	969	46.900000	health, disease, symptom, treatment, diet, healthy, body, weight, cause, food
4	2	129	131	1.500000	ivf, donor, fertility, sperm, egg, attain, cycle, bank, infertility, success
8	0	33	33	0.000000	volkswagen, gti, rabbit, cylinder, stabilization, hatchback, esp, standard, clearance, door
10	0	44	44	0.000000	disc, spinal, spine, facet, seminar, stenosis, degenerative, mri, pain, degeneration
11	0	56	56	0.000000	aqualyse, legionella, ionisation, ion, facility, ionization, proposal, water, copper, domestic

5.4.2 Full stripped

На основу дендрограма је одређено 13 кластера.





У овом случају 1 кластер садржи скоро све инстанце. Ово не представља корисну поделу и нема разлога да се даље анализира.

true_label	accepted	rejected	total	pct_accepted	top_terms
cluster					
8	49	0	49	100.000000	acreage, raise, poultry, country, beautiful, subscription, chicken, magazine, pond, backyard
9	68	0	68	100.000000	law, veterinary, justanswer, avatar, jpg, veterinarian, upload, appliance, positive, accept
11	22	0	22	100.000000	yoplait, smoothie, loser, biggest, smoothy, nbc, tuesday, frozen, idea, cool
7	43	0	43	100.000000	platinum, athletic, performance, pak, reproduction, hoof, equine, density, allergy, metabolic
5	35	2	37	94.600000	acai, berry, colon, julia, trial, cleanse, diet, lost, week, lose
0	96	12	108	88.900000	livestock, farm, review, nj, classifi, post, mi, feed, brunswick, piscataway
2	103	22	125	82.400000	compare, amazon, yahoo, rabbit, price, review, deal, shop, result, merchant
1	1391	1157	2548	54.600000	found, treatment, health, care, food, disease, call, pet, time, email
3	2	98	100	2.000000	cancer, mesothelioma, arthritis, lung, symptom, health, rheumatoid, crohn, treatment, disease
4	0	44	44	0.000000	disc, spinal, spine, facet, seminar, stenosis, degenerative, mri, lsi, pain
6	0	56	56	0.000000	aqualyse, legionella, ionisation, ion, facility, ionization, proposal, water, copper, domestic
10	0	32	32	0.000000	ivf, attain, fertility, integram, baby, chance, cycle, refund, month, success
12	0	33	33	0.000000	volkswagen, gti, rabbit, cylinder, stabilization, hatchback, esp, standard, clearance, door

5.5 hdbscan

Код hdbscan алгоритма није пронађена ниједна комбинација параметра која доводи до приближно корисног кластеровања. Кластера буде или преко 100 или их буде 2-3 или проценат звука буде преко 50. Ово нам указује на то да структура података није таква да постоје јасно подељени кластери уз додатак звука него су подаци врло помешани и кластери се у великој мери преклапају. Овај резултат указује на то да нема потребе покушавати друге алгоритме базиране на густини.

Scanning parameters:					
min_cluster_size	min_samples	n_clusters	noise_pct	silhouette	
2	2	386	38.8%	0.4592	
2	5	133	52.6%	0.5270	
2	10	64	63.2%	0.5204	
2	15	46	69.9%	0.5399	
2	2 (=mcs)	386	38.8%	0.4592	
5	2	164	44.3%	0.4878	
5	5	109	52.6%	0.5310	
5	10	56	63.5%	0.5281	
5	15	35	70.4%	0.5494	
5	5 (=mcs)	109	52.6%	0.5310	
10	2	71	51.5%	0.4219	
10	5	62	58.3%	0.4875	
10	10	53	63.9%	0.5249	
10	15	31	70.9%	0.5491	
10	10 (=mcs)	53	63.9%	0.5249	
15	2	50	55.7%	0.4054	
15	5	47	61.4%	0.4764	
15	10	38	66.9%	0.5230	
15	15	30	71.2%	0.5513	
15	15 (=mcs)	30	71.2%	0.5513	
20	2	35	58.7%	0.3685	
20	5	30	65.5%	0.4146	
20	10	26	70.3%	0.4902	
20	15	22	72.9%	0.5148	
20	20 (=mcs)	20	73.7%	0.4896	
30	2	19	67.8%	0.3423	
30	5	18	69.9%	0.3659	
30	10	13	74.2%	0.3969	
30	15	14	75.3%	0.4328	
30	30 (=mcs)	13	80.9%	0.5421	
50	2	2	0.0%	0.0235	
50	5	2	0.7%	0.0253	
50	10	2	3.6%	0.0390	
50	15	2	8.5%	0.0286	
50	50 (=mcs)	3	87.3%	0.2929	
75	2	2	54.2%	0.0432	
75	5	2	65.2%	0.0609	
75	10	2	73.8%	0.0461	
75	15	2	82.2%	0.0686	
75	75 (=mcs)	0	100.0%	N/A	
100	2	3	76.4%	0.0628	
100	5	2	85.3%	0.0793	
100	10	2	88.3%	0.1145	
100	15	0	100.0%	N/A	
100	100 (=mcs)	0	100.0%	N/A	

Scanning parameters:					
min_cluster_size	min_samples	n_clusters	noise_pct	silhouette	
2	2	400	36.9%	0.4855	
2	5	128	54.6%	0.5331	
2	10	69	65.7%	0.5169	
2	15	43	71.9%	0.5334	
2	2 (=mcs)	400	36.9%	0.4855	
5	2	166	46.0%	0.4896	
5	5	106	55.3%	0.5414	
5	10	52	64.7%	0.5117	
5	15	33	72.2%	0.5344	
5	5 (=mcs)	106	55.3%	0.5414	
10	2	68	54.7%	0.4237	
10	5	58	61.3%	0.4741	
10	10	46	65.3%	0.4970	
10	15	29	72.9%	0.5402	
10	10 (=mcs)	46	65.3%	0.4970	
15	2	47	59.2%	0.4045	
15	5	40	65.3%	0.4556	
15	10	34	69.6%	0.5146	
15	15	27	73.7%	0.5407	
15	15 (=mcs)	27	73.7%	0.5407	
20	2	31	61.2%	0.3541	
20	5	26	68.1%	0.4058	
20	10	24	72.0%	0.4709	
20	15	21	73.5%	0.4725	
20	20 (=mcs)	19	75.2%	0.4713	
30	2	19	67.2%	0.2963	
30	5	15	72.0%	0.3448	
30	10	15	74.6%	0.3904	
30	15	12	74.4%	0.3588	
30	30 (=mcs)	11	80.2%	0.4549	
50	2	2	1.1%	0.0220	
50	5	2	4.8%	0.0260	
50	10	2	13.2%	0.0238	
50	15	8	75.3%	0.2456	
50	50 (=mcs)	4	89.9%	0.3890	
75	2	3	83.1%	0.1092	
75	5	2	66.2%	0.0332	
75	10	2	69.3%	0.0400	
75	15	2	73.4%	0.0469	
75	75 (=mcs)	0	100.0%	N/A	
100	2	3	83.1%	0.1092	
100	5	2	66.2%	0.0332	
100	10	2	69.3%	0.0400	
100	15	2	87.9%	0.1007	
100	100 (=mcs)	0	100.0%	N/A	


5.6 Гаусова мешавина модела

Зато што су подаци l_2 -нормализовани сви леже на јединишној сфери. Због тога је изабрана сферна коваријација за параметар типа коваријације модела. Након одређивања броја кластера тренирани су модели са осталим типовима коваријација ради поређења.


GMM Metrics at k=40 — Reduced Stripped				
	BIC	Silhouette	Calinski-Harabasz	Davies-Bouldin
Covariance				
full	56686946.6	0.1185	26.9	3.3
tied	-7629725.7	0.1278	28.0	2.9
diag	-10793364.0	0.0732	19.6	4.2
spherical	-9916390.5	0.1179	28.1	2.8
GMM Metrics at k=40 — Full Stripped				
	BIC	Silhouette	Calinski-Harabasz	Davies-Bouldin
Covariance				
full	158798148.7	0.1103	21.9	3.8
tied	-11553039.2	0.1251	23.6	3.2
diag	-19202896.0	0.0766	17.1	5.1
spherical	-17104969.8	0.1211	23.2	2.8

Tied има сличне резултате као spherical док друга два типа имају знатно лошије.

5.6.1 Reduced stripped



При додељивању кластера инстанцама вероватноћа је скоро 1 (Mean confidence (max probability): 0.998) тако да не постоје меке доделе него се алгоритам понаша као алгоритам к средина.




Расподела и најчешће речи су такође указују на сличност алгоритму к средина. Расподела и најчешће речи у кластерима су врло слични претходним алгоритмима.

true_label	accepted	rejected	total	pct_accepted	top_terms
cluster					
2	22	0	22	100.000000	smoothie, loser, biggest, smoothy, nbc, tuesday, frozen, idea, cool, fruit
6	66	0	66	100.000000	law, veterinary, justanswer, avatar, jpg, veterinarian, upload, appliance, positive, immigration
17	19	0	19	100.000000	hobby, poultry, livestock, alpaca, coop, farm, post, hydraulic, backyard, brooder
37	18	0	18	100.000000	cage, supply, pet, ferret, litter, clearance, bird, rabbit, low, habitat
36	56	0	56	100.000000	hunt, deer, game, hunter, goose, call, creek, elk, predator, trophy
21	42	0	42	100.000000	platinum, athletic, performance, reproduction, pak, hoof, equine, density, allergy, metabolic
10	15	0	15	100.000000	kitten, cat, identification, neuter, rescue, club, tag, behavior, adoption, checklist
30	74	1	75	98.700000	livestock, raise, subscription, acreage, machinery, poultry, renew, radio, classifi, breed
32	81	3	84	96.400000	dog, pet, cat, food, groomer, supply, treat, care, flea, supplement
39	82	6	88	93.200000	recipe, diet, weight, fat, healthy, lose, cook, food, loss, vegetable
19	54	4	58	93.100000	soap, oil, handmade, natural, bath, milk, goat, lotion, skin, scent
4	27	2	29	93.100000	acai, berry, colon, julia, trial, cleanse, diet, lost, charge, trend
11	57	6	63	90.500000	oop, visibility, alert, exist, newly, upper, unable, invalid, valid, cancel
33	9	1	10	90.000000	sound, effect, collection, ton, download, llc, music, presentation, format, spice
8	49	9	58	84.500000	furniture, clothing, gift, shop, sho, toy, baby, electronics, accessory, price
5	52	11	63	82.500000	nj, brunswick, piscataway, restaurant, mi, review, feed, phone, local, map
29	108	28	136	79.400000	milk, cheese, organic, dairy, goat, meat, beef, food, farm, natural
27	27	8	35	77.100000	image, webcrawler, filter, preference, sponsore, web, jpg, moderate, similar, white
15	15	6	21	71.400000	business, livestock, equipment, quickly, supply, found, solution, cattle, meat, handle
0	103	42	145	71.000000	weight, diet, health, supplement, body, vitamin, natural, loss, food, healthy
1	37	16	53	69.800000	compare, yahoo, amazon, deal, rabbit, coupon, sponsor, price, marketplace, result
12	530	349	879	60.300000	email, sale, business, please, time, call, offer, family, save, day
35	6	4	10	60.000000	donate, vision, eye, research, fight, meal, donation, valid, original, america
7	78	71	149	52.300000	found, pig, rabbit, pet, supply, trust, treatment, save, name, baby
23	18	18	36	50.000000	acr, farm, land, estate, county, city, house, sale, equipment, tractor
24	107	122	229	46.700000	equipment, design, system, steel, custom, livestock, industry, fence, farm, water
14	5	11	16	31.200000	installation, flash, player, nutritional, llc, website, audience, solely, content, encourage
28	47	272	319	14.700000	treatment, symptom, disease, patient, pain, health, cause, doctor, medical, disorder
38	3	43	46	6.500000	disease, symptom, found, parkinson, cough, crohn, treatment, sclerosis, answer, prescrib
25	2	35	37	5.400000	rheumatoid, arthritis, everyday, pain, ra, rheumatic, rheumatologist, symptom, health, relaxation
3	0	19	19	0.000000	crohn, bowel, healthline, drug, disease, unknown, encyclopedia, bipolar, cause, symptom
13	0	19	19	0.000000	spinal, seminar, stenosis, disc, facet, spine, endoscopic, pain, upcome, md
22	0	34	34	0.000000	pregnancy, pregnant, baby, week, calendar, toddler, labor, ovulation, development, quiz
20	0	29	29	0.000000	ivf, attain, fertility, baby, chance, month, cycle, refund, specialist, success
16	0	33	33	0.000000	volkswagen, gti, rabbit, cylinder, stabilization, hatchback, esp, standard, clearance, door
18	0	54	54	0.000000	cancer, mesothelioma, lung, treatment, diagnosis, colon, found, md, lawyer, ovarian
9	0	52	52	0.000000	aqualyse, legionella, ionisation, ion, facility, ionization, proposal, water, copper, domestic
26	0	81	81	0.000000	donor, sperm, ivf, bank, egg, fertility, reproductive, infertility, patient, donation
31	0	50	50	0.000000	crohn, disease, colitis, inflammation, symptom, cause, inflammatory, pain, ulcerative, affect
34	0	17	17	0.000000	degenerative, disc, spine, degeneration, spinal, mri, facet, stenosis, seminar, disease

5.6.2 Full stripped

Раподела је скоро иста као код reduced stripped, чак је и мало мања варијација. Даља анализа такође не открива ништа ново.



true_label	accepted	rejected	total	pct_accepted	top_terms
cluster					
1	31	0	31	100.000000	poultry, geese, chicken, coop, backyard, acreage, raise, duck, country, bantam
4	62	0	62	100.000000	law, veterinary, justanswer, avatar, jpg, veterinarian, appliance, upload, positive, jodi
33	11	0	11	100.000000	livestock, equipment, quickly, business, supply, found, handle, cattle, swine, wholesale
32	22	0	22	100.000000	yoplait, smoothie, loser, biggest, smoothy, nbc, tuesday, frozen, idea, cool
24	42	0	42	100.000000	platinum, athletic, performance, reproduction, pak, hoof, equine, density, allergy, metabolic
22	15	0	15	100.000000	cass, hunt, deer, goose, game, nomad, predator, creek, fox, electronic
19	32	0	32	100.000000	supply, pet, rabbit, trust, drsfostersmith, guinea, foster, cage, pig, name
15	34	0	34	100.000000	kitten, hobby, thread, nor, post, breed, subscriber, farm, litterbox, cat
0	46	1	47	97.900000	hunt, deer, ranch, whitetail, trophy, outfitter, lodge, hunter, elk, game
3	43	1	44	97.700000	livestock, classifi, agriculture, ag, machinery, sheep, farmer, subscription, comment, hog
26	71	3	74	95.900000	dog, pet, cat, groomer, food, supply, treat, flea, care, supplement
2	46	2	48	95.800000	fed, organic, beef, grass, alfalfa, meat, lb, steak, farm, pork
29	61	3	64	95.300000	recipe, cheese, cook, flavor, fat, sauce, salad, bread, diet, lose
18	54	4	58	93.100000	soap, oil, natural, handmade, milk, bath, goat, lotion, skin, scent
5	27	2	29	93.100000	acai, berry, colon, julia, trial, cleanse, diet, lost, charge, trend
14	58	6	64	90.600000	oop, visibility, alert, exist, newly, upper, unable, invalid, valid, cancel
21	52	11	63	82.500000	nj, brunswick, piscataway, restaurant, mi, review, feed, phone, local, map
27	129	29	158	81.600000	diet, weight, loss, healthy, health, fat, food, body, lose, vitamin
28	13	3	16	81.200000	parkchester, staten, condominium, condo, acr, farm, equipment, york, catholic, island
36	36	13	49	73.500000	compare, yahoo, amazon, deal, rabbit, coupon, marketplace, sponsor, price, result
12	796	529	1325	60.100000	sale, email, price, time, design, offer, save, call, farm, please
6	70	110	180	38.900000	found, cancer, treatment, symptom, disease, lollipop, pig, baby, innovative, pertussis
17	6	24	30	20.000000	donor, bank, donation, egg, recipient, fee, reproductive, sperm, biology, donate
23	12	49	61	19.700000	rheumatoid, arthritis, everyday, pain, health, symptom, ra, flu, rheumatic, rheumatologist
38	37	273	310	11.900000	symptom, treatment, disease, pain, cause, patient, doctor, health, disorder, condition
11	3	36	39	7.700000	cryogenic, siemen, tank, industry, globalspec, liquid, solution, water, equipment, storage
7	0	33	33	0.000000	volkswagen, gti, rabbit, cylinder, stabilization, hatchback, esp, standard, clearance, door
16	0	28	28	0.000000	pregnancy, pregnant, week, baby, calendar, trimester, childbirth, toddler, ovulation, development
10	0	52	52	0.000000	aqualyse, legionella, ionisation, ion, facility, ionization, proposal, water, copper, domestic
9	0	19	19	0.000000	crohn, bowel, healthline, gale, drug, disease, unknown, encyclopedia, bipolar, cause
8	0	72	72	0.000000	sperm, fertility, ivf, donor, infertility, bank, reproductive, patient, egg, treatment
13	0	35	35	0.000000	mesothelioma, cancer, lung, mesothelioma, asbesto, happyhealthyrecipe, md, mesothelium, colon, ovarian
20	0	15	15	0.000000	county, realty, land, lake, landsofamerica, auction, acreage, rural, acr, estate
31	0	9	9	0.000000	osteoporosis, bisphosphonate, fracture, copn, ontario, atypical, canada, oct, calcium, aware
25	0	17	17	0.000000	degenerative, disc, lsi, spine, spondylosis, degeneration, spinal, lumbago, vertebrae, mri
30	0	22	22	0.000000	ivf, attain, integram, fertility, chance, baby, cycle, month, refund, specialist
35	0	15	15	0.000000	whoop, cough, palsy, cerebral, disability, fibromyalgia, prevent, treat, social, answer
34	0	19	19	0.000000	liu, spinal, asc, seminar, atlantic, stenosis, disc, facet, spine, endoscopic
37	0	10	10	0.000000	lactaid, mcneil, installation, flash, nutritional, player, llc, website, audience, solely
39	0	11	11	0.000000	tunturi, elliptical, healthdesk, trainer, cf, crosstrainer, stamina, cardio, cross, machine

5.7 Закључак

Анализа показује да подаци нису јасно раздвојиви него да постоји велика количина преклапање међу кластерима, такође не постоји јасан избор броја кластера јер све метрике настављају да се побољшавају са растом броја кластера тако да крајњи избор зависи од даље примене.

	Algorithm	Dataset	Number of Clusters	Silhouette	Calinski-Harabasz	Davies-Bouldin
0	KMeans	Reduced Stripped	38.000000	0.129958	29.947824	2.903968
1	KMeans	Full Stripped	38.000000	0.116605	24.282312	3.226623
2	Bisecting KMeans	Reduced Stripped	38.000000	0.097970	23.621998	4.024145
3	Bisecting KMeans	Full Stripped	38.000000	0.074918	16.412614	4.862145
4	Agglomerative clustering	Reduced Stripped	12.000000	0.054182	43.665119	3.025491
5	Agglomerative clustering	Full Stripped	13.000000	0.065537	38.235047	2.134568
6	HDBSCAN	Reduced Stripped	nan	nan	nan	nan
7	HDBSCAN	Full Stripped	nan	nan	nan	nan
8	Gaussian mixture model	reduced Stripped	40.000000	0.119839	27.878658	2.892715
9	Gaussian mixture model	full Stripped	40.000000	0.111192	22.854085	2.846424

Може се видети да резултати добијени коришћењем Reduced stripped скупа података бољи од Full stripped иако X_tfidf_reduced_stripped има 3531 атрибута док X_tfidf_full_stripped има 43563 и X_lsa_reduced_stripped има 700 атрибута а X_lsa_full_stripped има 1100 тако да је редукција атрибута очигледан избор.

Алгоритам к средина има најбоље резултате(Calinski и Davies код агломеративног кластеровања су вештачки високи и дато кластеровање није примењиво јер групишу скоро све податке у само 1 кластер). Бисекција к средина иако има мало лошије резултате од обичног алгоритма к средина што се метрика тиче даје много униформнију расподелу инстанци по кластерима тако да може представити бољи избор у зависности од ситуације.

6 Класификација

За класификацију су коришћени скупови података:

- Reduced stripped - Скуп података добијен скидањем префикса и одбацивањем речи које се појављују превише ретко или превише често у тексту.
- Reduced prefixed - Скуп података добијен задржавањем префикса и одбацивањем речи које се појављују превише ретко или превише често у тексту.
- Full stripped - Скуп података добијен скидањем префикса и без редукције атрибута.
- Full prefixed - Скуп података добијем задржавањем префикса и без редукције атрибута.

Сваки скуп података је даље подељен на скуп за тренирање и скуп за тестирање а за унакрсну валидацију је коришћена стратификована подела на 3 подскупа.

6.1 Bagging

Код ансамбл метода базираних на дрвету одлучивања је направљено основно дрво одлучивања да служи као полазна тачка ради поређења резултата. За класификатор се користи BaggingClassifier из sklearn библиотеке

уз out of bag score параметар ради тестирања на скупу података који нису изабрани за тренирање модела при извлачењу узорка. За оптимизацију хиперпараметара се користи RandomizedSearchCV sklearn библиотеке.

	Dataset	Test ROC-AUC	Test Accuracy	n_estimators	max_samples	max_features	estimator__min_samples_split	estimator__min_samples_leaf	estimator__max_depth
0	Reduced Stripped	0.936464	0.862175	100	0.9	0.6	2	2	15
1	Reduced Prefixed	0.920611	0.842266	150	0.5	0.5	5	1	20
2	Full Stripped	0.933540	0.860643	150	0.9	0.6	2	2	10
3	Full Prefixed	0.930132	0.856049	100	0.8	0.6	5	2	20

	TN	FP	FN	TP	Total
Dataset					
Reduced Stripped	225	66	24	338	653
Reduced Prefixed	223	68	35	327	653
Full Stripped	224	67	24	338	653
Full Prefixed	227	64	30	332	653

6.2 Random Forest

За класификатор се користи RandomForestClassifier из sklearn библиотеке уз out of bag score параметар ради тестирања на скупу података који нису изабрани за тренирање модела при извлачењу узорка. За оптимизацију хиперпараметара се користи RandomizedSearchCV sklearn библиотеке.

	Dataset	Test ROC-AUC	Test Accuracy	n_estimators	min_samples_split	min_samples_leaf	max_features	max_depth	bootstrap
0	Reduced Stripped	0.940499	0.859112	100	10	1	0.1	20	True
1	Reduced Prefixed	0.928618	0.856049	100	10	1	0.1	20	True
2	Full Stripped	0.935932	0.862175	100	10	1	0.1	20	True
3	Full Prefixed	0.936497	0.860643	100	10	1	0.1	20	True

	TN	FP	FN	TP	Total
Dataset					
Reduced Stripped	223	68	24	338	653
Reduced Prefixed	227	64	30	332	653
Full Stripped	230	61	29	333	653
Full Prefixed	226	65	26	336	653

6.3 XGBoost

За пример boosting ансамбл методе коришћен је XGBClassifier xgboost библиотеке и за оптимизацију хиперпараметара је коришћена Бајесова оптимизација помоћу hyperopt библиотеке. Прво је направљен xgboost класификатор са подразумеваним параметрима као полазна тачка, даље је дефинисан простор претраге и функција коју треба минимизирати. За оптимизацију је уместо унакрсне валидације коришћен одвојен валидациони скуп (20% тренинг скупа) зато што се тестирањем показало да је унакрсна валидација превише спора.

	Dataset	Test ROC-AUC	Test Accuracy	colsample_bytree	gamma	learning_rate	max_depth	min_child_weight	n_estimators	reg_alpha	reg_lambda	subsample
0	Reduced Stripped	0.935695	0.862175	0.711338	0.814424	0.061416	7	9	250	2.863041	0.258587	0.834317
1	Reduced Prefixed	0.928106	0.860643	0.597769	1.197722	0.048067	7	6	300	0.074296	3.465535	0.824666
2	Full Stripped	0.927237	0.868300	0.416502	0.120334	0.035284	8	7	150	0.079588	3.202974	0.999698
3	Full Prefixed	0.933588	0.866769	0.532908	0.662562	0.077620	6	8	100	0.066000	1.017479	0.989298

	TN	FP	FN	TP	Total
Dataset					
Reduced Stripped	234	57	33	329	653
Reduced Prefixed	236	55	36	326	653
Full Stripped	235	56	30	332	653
Full Prefixed	242	49	38	324	653

Резултати су добри али поредећи оптимизован и почетни модел може се видети да оптимизацијом хиперпараметара нису постигнути бољи резултати. Стандардни хgboost са подразумеваним параметрима је већ толико оптимизован и добар на оваквом скупу података да нема много простора за напредак. Притом подразумевани хgboost већ има око 0.93 AUC(зависи од скупа података) што је исто колико и bagging и random forrest класификатори што указује да је то вероватно и горња граница за овај скуп података и да преостала грешка представља урођену варијабилост скупа података.

6.4 Support vector machine

За класификатор се користи SGDClassifier из sklearn библиотеке са hinge функцијом грешке чиме се добија метод потпортних вектора. За оптимизацију хиперпараметара се користи RandomizedSearchCV sklearn библиотеке.

	Dataset	Test ROC-AUC	Test Accuracy	alpha	l1_ratio	penalty
0	Reduced Stripped	0.941163	0.892802	0.000283	0.3	elasticnet
1	Reduced Prefixed	0.932937	0.872894	0.000985	1.0	elasticnet
2	Full Stripped	0.944457	0.906585	0.000283	0.3	elasticnet
3	Full Prefixed	0.945682	0.891271	0.000283	0.3	elasticnet

	TN	FP	FN	TP	Total
Dataset					
Reduced Stripped	254	37	33	329	653
Reduced Prefixed	242	49	34	328	653
Full Stripped	257	34	27	335	653
Full Prefixed	249	42	29	333	653

Слично као код хgboost класификатора, овде је на 3 скупа података добијено минимално побољшање оптимизацијом док се на једаном AUC смањило за 0.001. Такође је AUC око 0.93 што подржава идеју да је то горња граница.

6.5 Logistic regression

За класификатор се користи SGDClassifier из sklearn библиотеке са log_loss функцијом грешке чиме се добија логистичка регресија. За оптимизацију хиперпараметара се користи RandomizedSearchCV sklearn библиотеке.

	Dataset	Test ROC-AUC	Test Accuracy	alpha	l1_ratio	penalty
0	Reduced Stripped	0.944068	0.892802	0.000205	0.5	elasticnet
1	Reduced Prefixed	0.940589	0.883614	0.000254	0.1	elasticnet
2	Full Stripped	0.950219	0.905054	0.000137	0.2	elasticnet
3	Full Prefixed	0.947182	0.888208	0.000181	0.4	elasticnet

	TN	FP	FN	TP	Total
Dataset					
Reduced Stripped	242	49	21	341	653
Reduced Prefixed	240	51	25	337	653
Full Stripped	246	45	17	345	653
Full Prefixed	244	47	26	336	653

И код логистичке регресије оптимизација не доводи до повећања AUC мере а овде је чак и вредност за нијансу већа(9.4 - 9.5).

6.6 Поређење резултата

6.6.1 Поређење ROC-AUC по скупу података:

Test ROC-AUC by Dataset and Model					
Model	Bagging	Logistic Regression	Random Forest	SVM	XGBoost
Dataset					
Full Prefixed	0.930	0.947	0.936	0.946	0.934
Full Stripped	0.934	0.950	0.936	0.944	0.927
Reduced Prefixed	0.921	0.941	0.929	0.933	0.928
Reduced Stripped	0.936	0.944	0.940	0.941	0.936

Не постоји велика разлика између резултата различитих модела на сваком од скупа података (разлика је око 0.02 између најбољег и најлошијег резултата за сваки скуп) али је на сваком скупу логистичка регресија модел са најбољим резултатом а након ње метод потпорних вектора. Ово указује на линеарну границу међу скуповима и додатно објашњава зашто оптимизација комплекснијих и изражајнијих модела није довела до побољшања резултата.

6.6.2 Поређење тачности по скупу података:

Test Accuracy by Dataset and Model, colored by model					
Model	Bagging	Logistic Regression	Random Forest	SVM	XGBoost
Dataset					
Full Prefixed	0.856	0.888	0.861	0.891	0.867
Full Stripped	0.861	0.905	0.862	0.907	0.868
Reduced Prefixed	0.842	0.884	0.856	0.873	0.861
Reduced Stripped	0.862	0.893	0.859	0.893	0.862

Поново логистичка регресија и метод потпорних вектора имају најбоље резултате.

6.6.3 Поређење ROC-AUC моделу:

Test ROC-AUC by Dataset and Model					
Model	Bagging	Logistic Regression	Random Forest	SVM	XGBoost
Dataset					
Full Prefixed	0.930	0.947	0.936	0.946	0.934
Full Stripped	0.934	0.950	0.936	0.944	0.927
Reduced Prefixed	0.921	0.941	0.929	0.933	0.928
Reduced Stripped	0.936	0.944	0.940	0.941	0.936

Најупечатљивије запажање је да као код кластеровања reduced prefixed скуп постиже најлошије резултате али за разлику од кластеровања преостала 3 скупа имају врло сличне резултате. Reduced stripped је најбољи за 3 од 5 модела али не постоји универзално најбољи скуп за сваки модел. Највећи ROC-AUC је постигнут логистичком регресијом на full stripped скупу.

6.6.4 Поређење тачности по моделу:

Test Accuracy by Dataset and Model, colored by dataset					
Model	Bagging	Logistic Regression	Random Forest	SVM	XGBoost
Dataset					
Full Prefixed	0.856	0.888	0.861	0.891	0.867
Full Stripped	0.861	0.905	0.862	0.907	0.868
Reduced Prefixed	0.842	0.884	0.856	0.873	0.861
Reduced Stripped	0.862	0.893	0.859	0.893	0.862

Табела је слична као табела ROC-AUC по моделу и исто reduced prefixed има најлошије вредности али се овде full stripped показује као скуп са најбољим резултатима.